附录二：全国大学生统计建模大赛高频经典统计模型全解析！

以下梳理**大赛最核心、最高频的12类统计模型**，覆盖**预测分析、综合评价、效率评价、关联/差异检验、分类预测**五大竞赛主流题型，每类模型均明确**核心解决问题、建模前检验、关键建模步骤、建模后检验、结果解析、核心要点/注意事项**，完全贴合大赛“统计科学性、建模完整性、结果落地性”要求，内容详细且适配竞赛实操。

一、时间序列预测类（核心：单指标趋势预测，高频用于销量、产量、收支等预测）

1. ARIMA模型（自回归积分移动平均模型）

1.1 核心解决问题

单变量时间序列的**短期/中期趋势预测**,适用于有趋势/季节性的连续型时间序列（如新能源汽车销量、GDP增速、基金收支额）。

1.2 建模前检验（前提条件检验）

- **平稳性检验**：ADF单位根检验（核心），若P<0.05则序列平稳，非平稳需做1/2阶差分后再检验；
- **白噪声检验**：LB检验/Box-Pierce检验，P<0.05则序列存在非随机信息，适合建模（白噪声序列无建模价值）；
- **季节性检验**：若数据有季节特征（如月度销量），需做季节差分/识别季节阶数（SARIMA模型）。

1.3 关键建模步骤

(1) 数据预处理：缺失值/异常值处理，时间序列标准化（可选）；

(2) 平稳化处理：对非平稳序列做差分，直至通过ADF检验；

(3) 模型定阶：通过**ACF/PACF自相关图**初步判断p（自回归阶数）、q（移动平

均阶数），结合**AIC/BIC信息准则**确定最优阶数ARIMA(p,d,q)（d为差分阶数）；

(4) 参数估计：采用极大似然估计/最小二乘法估计模型参数；

(5) 模型拟合：代入原始序列得到拟合值，为后续检验和预测做基础。

1.4 建模后检验（模型有效性检验，核心为残差检验）

- **残差白噪声检验**：LB 检验，P>0.05 则残差为纯随机噪声，模型提取完所有有效信息；
- **残差正态性检验**：Shapiro-Wilk 检验/Q-Q 图，残差近似正态分布，预测区间更科学；
- **残差方差齐性**：异方差检验（如LM检验），P>0.05则残差方差稳定，无波动异质性；
- **拟合优度评价**：计算 R^2（越接近1越好）、MAPE（平均绝对百分比误差，<10%为优秀，<20%为良好）、RMSE（均方根误差，越小越好）。

1.5 结果解析

- **点预测**：给出未来n期的具体预测值，为核心趋势判断；
- **区间预测**：输出95%/90%置信区间，体现预测的统计不确定性（大赛必写，提升科学性）；
- **拟合效果**：结合拟合优度指标说明模型精准度，对比实际值与拟合值的趋势一致性；
- **趋势解读**：分析预测值的增长/下降/平稳趋势，结合实际问题解释趋势成因（如政策、市场因素）。

1.6 核心要点/注意事项

- 定阶优先以AIC/BIC为准（ACF/PACF仅为初步判断，易受异常值影响）；
- 差分阶数不宜过高（一般≤2阶），否则会丢失序列信息；
- 大赛中建议结合**多元回归**做融合（ARIMA-多元回归），纳入影响因素（如政策、经济指标），提升预测精准度，体现创新；
- 预测期数不宜过长（一般≤3年），时间序列长期预测误差会显著增大。

2. GM(1,1)灰色预测模型

2.1 核心解决问题

小样本、少数据、信息不完全的单变量时间序列预测（如县域文旅消费潜力、中小企业营收），对数据要求低，大赛中常与综合评价结合使用。

2.2 建模前检验（数据适用性检验）

- **级比检验**：计算原始序列级比λ(k)，若λ(k)落在(0.1353,3.1972)区间，序列适合建GM(1,1)，否则需做平移变换；
- **数据预处理**：对原始序列做一次累加生成（1-AGO），得到新的平稳序列（GM(1,1)核心步骤）。

2.3 关键建模步骤

(1) 原始序列验证：级比检验，不通过则做平移变换；

(2) 一次累加生成：将非平稳的原始序列转化为平稳的累加序列；

(3) 构建白化微分方程：求解模型参数a（发展系数）、b（灰作用量）；

(4) 建立预测模型：得到累加序列的预测公式，再做**累减还原**，得到原始序列的预测值；

(5) 模型拟合：代入原始数据得到拟合值，计算拟合误差。

2.4 建模后检验（大赛核心为后验差检验，缺一不可）

- **后验差检验**（核心）：计算**后验差比值C**和**小误差概率P**
- C<0.65且P>0.95:模型优秀;C<0.8且P>0.7:模型良好;C≥0.8或P≤0.7:模型不合格，需优化；
- **相对误差检验**：计算每期相对误差，平均相对误差<20%为合格；
- **级比偏差检验**：级比偏差值越小越好，一般<0.2为合格。

2.5 结果解析

- **点预测**：给出未来n期预测值，适合短期小样本预测（一般≤5期）；
- **模型精度**：通过后验差检验结果说明模型有效性（大赛必写C和P值）；
- **趋势分析**:根据发展系数a判断趋势——a>0为增长趋势,a<0为下降趋势,

|a|越大趋势越明显；

(1) **落地建议**：结合预测趋势，为实际问题提出针对性对策（如预测销量增长则建议扩大产能）。

2.6 核心要点/注意事项

(1) 原始序列样本量控制在 **4-10 个**（最佳 5-7 个），样本过多则不适合灰色预测；

(2) 累加生成是核心，不可省略，否则模型无意义；

(3) 模型不合格时，可通过**残差修正 GM(1,1)模型**优化（对残差序列再建 GM(1,1)，修正预测值）；

(4) 大赛中常与 TOPSIS/熵权法融合（先评价再预测），体现建模完整性，提升获奖概率。

二、综合评价类（核心：多指标打分排名，高频用于发展水平、成效、潜力评价）

1. TOPSIS 法（逼近理想解排序法）

1.1 核心解决问题

多指标下的**样本综合排序/评价**（如县域乡村振兴成效、城市文旅消费潜力、企业数字化转型水平），对数据分布无要求，操作简单，大赛最高频评价模型。

1.2 建模前检验（指标体系检验，大赛核心加分点）

- **指标相关性检验**：Pearson/Spearman 相关分析，剔除相关系数>0.8 的高度冗余指标，避免重复计分；
- **指标鉴别力检验**：变异系数分析，剔除变异系数<0.1 的无鉴别力指标（指标值几乎无差异，无评价意义）；
- **指标预处理**（必做，无预处理则模型无效）：
- 正向化：将逆向指标（如损耗率、污染量，越小越好）、适度指标（如 BMI，适中最好）转化为正向指标（越大越好）；
- 无量纲化：消除量纲影响，常用**极差标准化/Min-Max**（适合数据分布不均匀）、

Z-score 标准化（适合数据正态分布）。

1.3 关键建模步骤

(1) 构建指标体系：从经济/社会/环境等维度选取可量化指标，完成相关性/鉴别力检验；

(2) 指标预处理：正向化+无量纲化，得到标准化决策矩阵；

(3) 确定指标权重：大赛中优先用**组合权重**（AHP-熵权/熵权-变异系数），体现主观+客观结合，避免单一权重片面性；

(4) 构建加权标准化矩阵：将标准化矩阵与指标权重相乘；

(5) 确定正负理想解：正理想解（各指标最大值，最优方案）、负理想解（各指标最小值，最劣方案）；

(6) 计算欧式距离：各样本到正理想解的距离 D^+、到负理想解的距离 D^-；

(7) 计算贴近度 C_i：$C_i=D^-/(D^++D^-)$，$C_i\in[0,1]$，越接近 1 则样本综合评价越好。

1.4 建模后检验（模型稳健性检验，大赛必做，否则结果不可信）

- **灵敏度分析**（核心）：将各指标权重上下调整 10%-20%，观察样本贴近度/排名变化，若排名基本不变则模型稳健；
- **排名合理性检验**：结合实际情况验证排名（如经济发达省份评价得分应靠前），避免数值排名与实际脱节；
- **聚类分析验证**：将贴近度做 K-means 聚类，分为高/中/低三类，验证分类结果与实际的一致性。

1.5 结果解析

- **综合排名**：按贴近度从大到小排序，给出样本具体排名，为核心评价结果；
- **等级划分**：通过 K-means 聚类/阈值法将样本分为不同等级（如优秀/良好/一般/较差），让评价结果更直观；
- **指标贡献分析**：结合权重大小，分析对评价结果影响最大的指标（如权重最高的指标为核心影响因素）；
- **样本短板分析**：对比样本与正理想解的指标差距，指出各样本的薄弱指标（如某省份“基础设施指标”与正理想解差距大，为短板）。

1.6 核心要点/注意事项

- 指标预处理**正向化在前，无量纲化在后**，顺序不可颠倒；
- 权重是核心，**单一权重（仅 AHP/仅熵权）易被评委扣分**，大赛必做组合权重；
- 欧式距离可替换为**余弦距离**（适合指标间相关性强的情况），体现方法适配性；
- 评价结果不可仅罗列排名，需结合实际问题做**短板分析/区域差异分析**，提升研究深度。

2. 熵权法（客观权重确定方法，常与 TOPSIS/AHP 融合）

2.1 核心解决问题

根据**数据自身统计特征**确定指标客观权重（指标变异程度越大，信息含量越高，权重越大），无主观人为因素，常与主观权重（AHP）结合做组合权重，大赛中为**评价类模型必备步骤**。

2.2 建模前检验（同 TOPSIS，指标预处理+冗余检验）

- 指标正向化+无量纲化（必做，熵权法对指标方向/量纲敏感）；
- 指标相关性检验，剔除高度冗余指标。

2.3 关键建模步骤

(1) 指标预处理：得到标准化正向矩阵；

(2) 计算指标比重：对标准化矩阵做归一化，得到各样本在各指标下的比重 p_{ij}；

(3) 计算指标熵值 e_j：$e_j=-k\times\Sigma(p_{ij}\times\ln p_{ij})$（$k=1/\ln n$，n 为样本数），$e_j\in[0,1]$，熵值越小则指标信息含量越高；

(4) 计算差异系数 g_j：$g_j=1-e_j$，差异系数越大则指标区分能力越强；

(5) 计算指标权重 w_j：$w_j=g_j/\Sigma g_j$，所有指标权重和为 1。

2.4 建模后检验

- **权重合理性检验**：结合实际问题验证权重（如“经济指标”在乡村振兴评价

中权重应偏高）；

- **组合权重一致性检验**：与 AHP 主观权重结合时，检验二者权重的相关性，避免权重矛盾。

2.5 结果解析

- **指标权重分布**：给出各指标具体权重，说明权重大小的原因（如某指标权重高是因为其变异程度大，能有效区分样本）；
- **核心指标识别**：将权重前 3-5 的指标定为核心评价指标，为后续对策建议提供依据；
- **权重对比分析**：若做组合权重，对比主观权重与客观权重的差异，解释差异成因（如专家主观认为“政策指标”重要，但客观数据中其变异程度小，权重低）。

2.6 核心要点/注意事项

- 无量纲化后指标值不可为 0（否则 $\ln p_{ij}$ 无意义），可通过**平移变换**（所有值+0.001）处理；
- 熵权法**仅为权重确定方法，不可单独做综合评价**，必须与 TOPSIS/加权评分法结合；
- 对变异程度过小的指标，熵权法会赋予极低权重，符合统计逻辑，无需强行调整。

3. AHP 层次分析法（主观权重确定方法，常与熵权法融合）

核心解决问题

通过**专家打分/逻辑分析**确定指标主观权重，适合指标难以用数据量化、需结合经验判断的评价问题（如民生、政策类指标），大赛中与熵权法结合为**组合权重最优方案**。

3.1 建模前准备

- 构建层次结构模型：目标层（综合评价）→准则层（评价维度，如经济/社会）→指标层（具体指标）；

- 制定专家打分标度：采用 1-9 标度法（1=两指标同等重要，9=一指标极度重要于另一指标）。

3.2 关键建模步骤

(1) 构建判断矩阵：对同一层次的指标，两两比较重要性，得到判断矩阵 A（n 阶方阵，n 为指标数）；

(2) **一致性检验**（大赛必做，否则权重无效）：

(3) 计算一致性指标 CI=(λ_max-n)/(n-1)（λ_max 为判断矩阵最大特征值）；

(4) 查找平均随机一致性指标 RI（大赛有固定 RI 表，n=1-10）；

(5) 计算一致性比例 CR=CI/RI，**CR<0.1 则检验通过**，判断矩阵逻辑一致；CR≥0.1 则需修正判断矩阵；

(6) 计算指标权重：通过特征值法/和法/根法计算判断矩阵的特征向量，归一化后得到指标主观权重。

3.3 建模后检验

- 一致性检验（核心，步骤中已做，未通过则权重不可用）；
- 权重与实际的匹配性检验：避免出现“核心指标权重过低”的不合理情况。

3.4 结果解析

- **层次权重分布**：给出准则层+指标层的具体权重，说明专家打分的逻辑（如准则层中“创新能力”权重高，因专家认为其对企业发展至关重要）；
- **一致性检验结果**：报告 CR 值，说明判断矩阵逻辑一致，权重具有科学性；
- **组合权重融合**：与熵权法客观权重按比例融合（如主观权重占 0.4，客观权重占 0.6），给出最终组合权重。

3.5 核心要点/注意事项

- 判断矩阵为**正互反矩阵**（a_ij=1/a_ji），构建时需满足该性质，否则无效；
- CR≥0.1 时，需**修正判断矩阵**（调整两两比较的标度，使逻辑更一致），不可强行使用；
- 专家打分建议结合**3-5 名专家**的打分结果取均值,避免单一专家的主观偏差；
- 仅当指标有**明显的重要性差异**时使用 AHP，若指标重要性相近，建议直接用

熵权法。

三、效率评价类（核心：投入-产出效率测度，高频用于产业效率、物流效率、生产效率）

1. DEA 数据包络分析（含 BCC/CCR/SBM-DEA）

1.1 核心解决问题

多投入-多产出下的**决策单元（DMU）效率测度**（如工业企业绿色生产效率、生鲜物流配送效率、高校科研效率），无需设定生产函数，无主观权重，大赛高频效率评价模型。

1.2 常用模型分类

- **CCR 模型**：假设规模报酬不变，测度**综合技术效率**（TE）；
- **BCC 模型**：假设规模报酬可变，将综合技术效率分解为**纯技术效率（PTE）和规模效率（SE）**，TE=PTE×SE（大赛优先用 BCC，分解效率更深入）；
- **SBM-DEA 模型**：处理**非期望产出**（如污染物、损耗率），适合绿色效率/可持续效率评价（大赛双碳主题必备，体现创新）。

1.3 建模前检验（投入-产出指标检验）

- **指标同向性检验**：投入指标与产出指标需呈正相关（投入越多，合理产出应越多），通过 Pearson 相关分析验证；
- **指标冗余检验**：剔除高度相关的投入/产出指标，避免信息重叠；
- **样本量检验**：样本数（DMU）≥2×（投入指标数+产出指标数），否则模型结果不稳定（大赛必满足，否则需合并样本/剔除指标）。

1.4 关键建模步骤

(1) 确定决策单元（DMU）：如各城市/企业/省份，记为 n 个；

(2) 选取投入-产出指标：投入指标（如资本、人力、资金）、期望产出（如产值、利润、配送量）、非期望产出（如污染物、损耗率，SBM-DEA 需加入）；

(3) 选择 DEA 模型：一般选 BCC 模型，绿色效率评价选 SBM-DEA（非径向、非角

度）；

(4) 模型求解:通过DEA-solver/Lingo/SPSS求解,得到各DMU的效率值(∈[0,1],效率值=1为有效DMU,<1为无效DMU）；

(5) **投影分析**（大赛必做，提升落地性）：对无效DMU，计算投入冗余率和产出不足率，给出具体的投入优化/产出提升数值。

1.5 建模后检验

- **效率值合理性检验**：结合实际验证有效DMU（如经济发达/管理先进的企业效率值应=1）；
- **规模报酬分析**：判断无效DMU的规模报酬状态（递增/递减/不变），为规模优化提供依据；
- **稳健性检验**：剔除1-2个样本/指标，重新求解，排名基本不变则稳健。

1.6 结果解析

- **效率值排名**：按综合技术效率值从大到小排序，区分有效/无效DMU；
- **效率分解分析**（BCC模型）：对无效DMU，分析效率低下的原因——纯技术效率低（管理/技术落后）、规模效率低（规模过大/过小）；
- **投影分析结果**:给出无效DMU的具体改进数值(如某企业资本投入冗余20%,产值产出不足15%），为效率提升提供量化路径；
- **非期望产出分析**（SBM-DEA）：分析非期望产出对效率的影响（如污染物排放过多导致绿色效率降低），提出减排建议。

1.7 核心要点/注意事项

- 投入-产出指标**不可随意选取**，需贴合实际生产/运营逻辑（如生鲜物流投入为“配送时间、人力”，产出为“配送量、损耗率”）；
- 无效DMU的**投影分析是大赛加分点**，不可仅罗列效率值，需给出量化改进方向；
- SBM-DEA为**大赛双碳主题优选模型**，比传统DEA更科学，体现方法适配性；
- 效率值=1的有效DMU，可通过**TOPSIS法进一步排序**（DEA无法对有效DMU排序），实现全样本排名（大赛融合创新点）。

2. Malmquist 指数模型（DEA 延伸，动态效率分析）

2.1 核心解决问题

跨期动态效率变化分析，将效率变化分解为**技术进步指数（TC）和技术效率变化指数（EC）**，适用于分析近 3-5 年的效率动态变化（如中小企业数字化转型效率的年度变化），常与 DEA 结合使用。

2.2 建模前检验

同 DEA 模型（样本量、指标同向性、冗余检验），需为**面板数据**（时间序列+截面数据，如 31 省份 5 年的投入-产出数据）。

2.3 关键建模步骤

- 构建面板数据：确定时间维度 t（如 t=1-5）和截面维度 n（如 n=31 省份）；
- 基于 DEA-BCC/SBM-DEA 计算各期效率值；
- 计算 Malmquist 指数：MI=EC×TC，MI>1 则效率提升，MI=1 则效率不变，MI<1 则效率下降；
- 指数分解：EC 为技术效率变化（管理/制度优化），EC>1 则技术效率提升；TC 为技术进步（技术/设备升级），TC>1 则技术进步。

2.4 建模后检验

同 DEA 模型，验证效率变化的合理性（如某行业 MI>1 应因技术升级，与实际产业情况匹配）。

2.5 结果解析

- **动态效率趋势**：分析 MI 的年度变化趋势，判断效率整体是提升/下降/波动；
- **分解结果解读**：判断效率变化的核心驱动因素——EC>1、TC=1 则效率提升源于管理优化；TC>1、EC=1 则源于技术进步；
- **区域/行业差异**：对比不同区域/行业的 MI、EC、TC，分析差异成因（如东部地区 TC>1 源于技术投入高，中西部 EC>1 源于管理优化）。

2.6 核心要点/注意事项

- 仅适用于**面板数据**，单期截面数据无法使用；
- 需与**静态 DEA 效率**结合分析，先测度静态效率，再分析动态变化，体现研究完整性；
- 指数分解结果需结合**实际产业政策/技术发展**解释，避免单纯数值解读。

四、关联/差异检验类（核心：变量间关系/样本间差异分析，大赛所有题型的基础支撑）

1. 相关分析（Pearson/Spearman/Kendall）

1.1 核心解决问题

分析**两个变量间的线性/非线性关联程度**，大赛中为**指标筛选、影响因素初步判断**的基础步骤（如筛选销量的影响因素、检验指标冗余性）。

1.2 模型分类与适用场景

- **Pearson 相关分析**：适用于**正态分布、连续型数值变量**（如人均可支配收入与新能源汽车销量）；
- **Spearman 等级相关分析**：适用于**非正态分布/有序分类变量**（如学历等级与健康素养水平），无数据分布要求，大赛高频；
- **Kendall 和谐系数**：适用于**多评价者的一致性检验**（如多位专家打分的一致性）。

1.3 建模前检验

- Pearson 相关：正态性检验（Shapiro-Wilk 检验，P>0.05）；
- 数据预处理：缺失值/异常值处理（异常值对相关系数影响大）。

1.4 关键建模步骤

(1) 确定分析变量：两个待分析的变量（X,Y）；

(2) 选择相关分析方法：根据变量类型/分布选择 Pearson/Spearman；

(3) 计算相关系数 r 和 P 值：r∈[-1,1]，|r|越接近 1 则相关性越强；r>0 为正

相关，r<0 为负相关；

(4) 相关性判定：P<0.05 则相关性具有统计显著性。

1.5 建模后检验

异常值检验：剔除异常值后重新计算相关系数，若 r 变化小则结果稳健。

1.6 结果解析

- **相关性强度与方向：**如“人均可支配收入与新能源汽车销量呈显著正相关（r=0.82，P<0.001）”；
- **显著性判断：**P<0.05 为显著相关，P<0.01 为极显著相关，P>0.05 为无显著相关；
- **实际意义解读：**结合问题解释相关性（如人均收入越高，新能源汽车购买能力越强，故呈正相关）。

1.7 核心要点/注意事项

- **相关≠因果：**大赛中不可说“X 导致 Y”，只能说“X 与 Y 呈显著相关”；
- 异常值对 Pearson 相关系数影响极大，必须先处理异常值；
- 变量为有序分类变量时，**不可用 Pearson 相关**，否则结果错误。

2. 假设检验（t 检验/方差分析 ANOVA/卡方检验）

2.1 核心解决问题

分析**样本间的差异是否具有统计显著性**，大赛中为**区域/群体差异分析**的核心步骤，分为三类，对应不同变量类型：

检验方法	适用场景	核心解决问题
独立样本 t 检验	1 个二分类分类变量（如男/女）+1 个连续数值变量（如成绩）	两组样本的数值变量均值是否存在显著差异
单因素方差分析（ANOVA）	1 个多分类分类变量(如东/中/西）+1 个连续数值变量（如效率值）	多组样本的数值变量均值是否存在显著差异
卡方检验（χ^2）	2 个分类变量（如吸烟/不吸烟+患病/无病）	两个分类变量间是否存在显著关联

2.2 建模前检验（各方法前提条件）

A. t 检验/ANOVA：

- 正态性检验：各样本组的数值变量近似正态分布（Shapiro-Wilk 检验，P>0.05）；
- 方差齐性检验：各样本组的方差相等（Levene 检验，P>0.05）；
- 数据独立性：样本间相互独立（大赛默认满足，除非有重复测量）；

B. 卡方检验：

- 列联表单元格期望频数≥5 的个数占比≥80%，否则需做 Fisher 精确检验；
- 样本量充足，避免小样本导致结果偏差。

2.3 关键建模步骤

A. t 检验：

- 提出假设：H0（两组均值无差异），H1（两组均值有差异）；
- 计算 t 值和 P 值，P<0.05 则拒绝 H0，差异显著；

B. ANOVA：

- 提出假设：H0（多组均值无差异），H1（至少一组均值有差异）；
- 计算 F 值和 P 值，P<0.05 则拒绝 H0，再做**多重比较（LSD/Tukey）**，识别具体哪两组差异显著；

C. 卡方检验：

- 构建列联表：行变量为一个分类变量，列变量为另一个分类变量；
- 计算 χ^2 值和 P 值，P<0.05 则两个分类变量显著关联。

2.4 建模后检验

多重比较（ANOVA 必做）：避免仅判断“多组有差异”，需明确具体差异组；卡方检验可做**列联系数**，分析关联强度。

2.5 结果解析

A. t 检验/ANOVA：

- 报告检验统计量（t/F）和 P 值，如“东部与西部新能源销量存在显著差异（F=12.35，P<0.001）”；

- 多重比较结果：如“东部均值显著高于西部（P<0.01），与中部无显著差异（P>0.05）”；
- 差异幅度：计算均值差，说明差异的实际大小；

B. 卡方检验：

- 报告 χ^2 值和 P 值，如“吸烟与肺癌存在显著关联（χ^2=18.26，P<0.001）”；
- 列联系数：说明关联强度（如列联系数=0.35，为中等关联）；
- 交叉表分析：计算各单元格的构成比，解释关联特征（如吸烟者肺癌患病率为 20%，非吸烟者为 5%）。

2.6 核心要点/注意事项

- 多组比较**不可用多次 t 检验**（会增大一类错误概率），必须用 ANOVA+多重比较；
- t 检验/ANOVA 不满足正态性/方差齐性时，可做**非参数检验**（如 Mann-Whitney U 检验/Kruskal-Wallis H 检验）；
- 卡方检验仅分析**分类变量间的关联**，不可用于数值变量，且不可说明因果关系。

3. 回归分析（多元线性回归/Logistic 回归/面板数据回归）

3.1 核心解决问题

分析**自变量对因变量的量化影响**，大赛中为**影响因素分析、因果推断（统计层面）、模型融合**的核心工具，分为三类高频模型：

回归模型	因变量类型	核心解决问题	大赛适用场景
多元线性回归	连续数值变量（如销量、效率值）	多个自变量对连续因变量的线性量化影响	新能源销量影响因素、绿色金融生态效应
二元 Logistic 回归	二分类分类变量（如患病/无病、有效/无效）	多个自变量对二分类因变量的影响概率	健康素养影响因素、企业效率有效与否的影响因素
面板数据回归	面板数据的连续因变量	跨期/跨截面的自变量对因变量的影响	省级面板数据的绿色金融、新能源产业分析

3.2 建模前检验（核心，避免伪回归/结果偏差）

A. 多元线性回归：

- 线性性：自变量与因变量呈线性关系（散点图/相关分析）；
- 正态性：残差近似正态分布（Shapiro-Wilk 检验）；
- 无多重共线性：方差膨胀因子 VIF<10（VIF≥10 则存在严重共线性）；
- 无自相关：DW 检验（DW≈2 则无自相关）；
- 方差齐性：残差方差稳定（LM 检验，P>0.05）；

B. Logistic 回归：

- 无多重共线性：VIF<10；
- 样本量充足：事件数（因变量少数类）≥10×自变量数；

C. 面板数据回归：

- 平稳性检验：单位根检验（LLC/Levin 检验，P<0.05 则平稳）；
- 协整检验：Kao 检验（P<0.05 则存在长期均衡关系，避免伪回归）；
- 豪斯曼检验（Hausman）：P<0.05 选固定效应模型，P>0.05 选随机效应模型。

3.3 关键建模步骤

(1) 确定自变量（$X_1, X_2, ..., X_k$）和因变量（Y），做数据预处理（缺失值/异常值/标准化）；

(2) 做建模前检验，不满足条件则修正（如剔除共线性自变量、做差分）；

(3) 模型估计：采用最小二乘法（线性回归）/极大似然估计（Logistic 回归）估计回归系数 β；

(4) 变量筛选：采用**逐步回归**，剔除 P>0.05 的不显著自变量，得到最优回归模型；

(5) 模型拟合：代入自变量得到因变量拟合值，为后续检验做基础。

3.4 建模后检验（模型有效性+系数显著性）

- **系数显著性检验**：t 检验，P<0.05 则自变量对因变量的影响显著；
- **模型整体显著性检验**：F 检验（线性回归）/似然比检验（Logistic），P<0.05 则模型整体显著；
- **拟合优度评价**：
  - 线性回归：R^2（越接近 1 越好）、调整 R^2（消除自变量数影响）；
  - Logistic 回归：AUC 值（越接近 1 越好，AUC>0.7 为良好）、伪 R^2；

- **残差检验**：线性回归需验证残差的正态性/方差齐性/无自相关；
- **稳健性检验**：替换自变量指标/缩尾处理/分样本回归，若系数符号和显著性不变则模型稳健。

3.5 结果解析

- **回归系数解读**：
  - 线性回归：β>0 为正影响，β<0 为负影响，|β|越大影响越大（标准化系数可直接比较影响程度）；
  - Logistic 回归：报告 OR 值（优势比），OR>1 为危险因素，OR<1 为保护因素，OR=1 则无影响；
- **显著影响因素识别**：将 P<0.05 的自变量定为核心影响因素，按影响程度排序；
- **模型拟合效果**：报告拟合优度指标（如 R^2=0.85），说明模型对因变量的解释能力；
- **实际意义解读**：结合问题解释系数（如“充电桩数量每增加 1 万个，新能源汽车销量增加 0.5 万辆（β=0.5，P<0.01）”）。

3.6 核心要点/注意事项

- **多重共线性是回归分析的最大坑**，必须做 VIF 检验，共线性严重时可剔除自变量/做主成分分析；
- 自变量需**贴合实际逻辑**，不可盲目堆砌（一般控制在 10 个以内）；
- 面板数据回归**必做豪斯曼检验**，选择固定/随机效应，否则模型结果错误；
- 大赛中常与 ARIMA/TOPSIS 融合（如 ARIMA-多元回归预测、TOPSIS 得分做回归因变量），体现创新。

五、因子分析/主成分分析（核心：指标降维，高频用于多指标浓缩、综合指数构建）

1. 因子分析（FA）

1.1 核心解决问题

将**多个高度相关的指标**浓缩为少数几个互不相关的公因子（如将 10 个经济指标浓缩为“经济规模因子”“经济效率因子”），实现指标降维，大赛中用于**综合指数构建、指标体系优化**。

1.2 建模前检验（数据适用性检验，大赛必做）

- **KMO 检验**：KMO≥0.6 则适合做因子分析，KMO≥0.7 为良好，KMO<0.6 则不适合；
- **Bartlett 球形度检验**：P<0.05 则指标间存在显著相关性，适合做因子分析；
- 数据预处理：指标正向化+标准化（因子分析对量纲/指标方向敏感）。

1.3 关键建模步骤

(1) 数据预处理+KMO/Bartlett 检验，验证适用性；

(2) 提取公因子：采用**主成分分析法**提取公因子，根据累计方差贡献率≥60%确定公因子个数；

(3) 因子旋转：采用**最大方差旋转（Varimax）**，使公因子的含义更清晰，便于解释；

(4) 计算因子载荷：因子载荷≥0.5 则指标与公因子的关联性强，否则剔除指标；

(5) 计算因子得分：采用回归法计算各样本的公因子得分；

(6) 构建综合因子得分：以**各公因子的方差贡献率为权重**，加权平均得到综合因子得分，用于排名/评价。

1.4 建模后检验（模型有效性检验，大赛核心三步）

- **因子载荷检验**：各指标因子载荷绝对值≥0.5，否则剔除指标；
- **公因子方差检验**：公因子方差≥0.4，说明指标被公因子解释的程度足够；
- **累计方差贡献率检验**：≥60%，说明公因子提取了原始指标的大部分信息。

1.5 结果解析

- **公因子命名**：根据因子载荷的指标构成，为各公因子命名（如因子 1 包含 GDP、人均收入，命名为“经济规模因子”）；
- **公因子解释能力**：报告各公因子的方差贡献率和累计方差贡献率（如累计方差贡献率=78.5%，提取了 78.5%的原始信息）；

- **因子得分排名**：按综合因子得分排序，给出样本排名，为综合评价结果；
- **公因子分析**：分析各样本在不同公因子上的得分，识别样本的优势/短板（如某省份“创新因子”得分高，“环境因子”得分低）。

1.6 核心要点/注意事项

- **因子旋转是必做步骤**，未旋转的公因子含义模糊，无法解释；
- 累计方差贡献率**不足 60%时**，需剔除公因子方差低的指标，重新做因子分析；
- 因子分析**不可单独做评价**，需计算综合因子得分，结合排名/聚类分析；
- 大赛中常与 TOPSIS/回归分析融合（如因子得分做 TOPSIS 指标/回归因变量），提升研究深度。

2. 主成分分析（PCA）

2.1 核心解决问题

与因子分析类似，**指标降维**，将多个相关指标转化为少数几个互不相关的主成分，适合**综合指数构建、数据降维后建模**（如主成分回归，解决多重共线性），比因子分析更简单，大赛中与因子分析二选一即可。

2.2 建模前检验

同因子分析（KMO 检验、Bartlett 球形度检验、数据标准化）。

2.3 关键建模步骤

(1) 数据预处理+适用性检验；

(2) 提取主成分：根据**特征值≥1** 和累计方差贡献率≥60%确定主成分个数；

(3) 计算主成分载荷：主成分载荷≥0.5 则指标与主成分关联性强；

(4) 计算主成分得分：得到各样本的主成分得分；

(5) 构建综合主成分得分：以主成分方差贡献率为权重，加权平均得到综合得分。

2.4 建模后检验

同因子分析（累计方差贡献率、主成分载荷检验）。

2.5 结果解析

同因子分析，核心为**主成分命名、综合得分排名、优势/短板分析**。

2.6 核心要点/注意事项

- 主成分分析与因子分析的区别：PCA 是**指标的线性组合**，因子分析是**指标的潜在因子**，大赛中根据研究目的选择（偏重于解释则用因子分析，偏重于降维建模则用 PCA）；
- 特征值≥1 为经验准则，优先以累计方差贡献率≥60%为准。

六、所有模型的大赛通用核心要求

- **检验完整**：建模前前提检验、建模后有效性检验**缺一不可**，无检验的模型视为无统计依据，评委直接扣分；
- **方法适配**：根据**问题类型、数据特征**选择模型（如小样本用 GM(1,1)，绿色效率用 SBM-DEA），拒绝“为了用模型而用模型”；
- **创新融合**：优先做**经典方法融合**（如 ARIMA-多元回归、DEA-TOPSIS），比单一模型更易获奖，且无需学习复杂模型；
- **结果落地**：避免单纯的数值解读，需结合**国家战略/实际问题**提出可量化、可操作的对策建议，体现“服务国家战略”；
- **统计显著性**：所有检验/分析均需**标注 P 值、统计量（t/F/χ^2）**，$P<0.05$ 为显著，大赛必写，体现统计科学性；
- **稳健性检验**：评价类/回归类/效率类模型**必做稳健性检验**（灵敏度分析/替换指标/分样本），说明结果可靠。